

AI 경진대회에 멀티 에이전트 팀으로 참가하기

Hermes Agent (DeepSeek, GPT, Claude)

전체 8위 · 대학원 426 그룹 2위

최용 · SCU_42600055

대회 개요 — 서울 아파트 실거래가 예측

test 531행 · RMSE 평가 · full-test 공개 점수 = 최종 점수

무엇을 예측했나

서울 아파트 실거래가 · 8구 24동 · test 531행

입력 피쳐 9개

구 · 동 · 면적 · 건축년도 · 층 · 지하철거리 · 거래시점 · 브랜드 · 공원

어떻게 채점했나

전체 test 공개 채점 (full-test)

private test 분할 없음 · 공개 리더보드 점수 = 최종 점수


full-test 공개 점수 = 최종 점수 · 리더보드 = 다음 판단을 위한 관측값

세 번의 도전 — 참가 방식의 변화

질문 — 사람의 판단은 어디까지 남기고, 어디부터 AI 팀에게 위임할 것인가

제3회

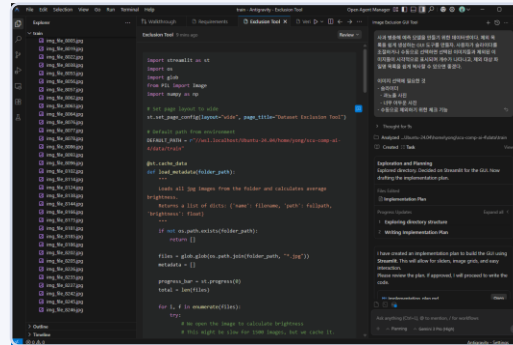
채팅 Q&A + 수동 실행



채팅창에 묻고, 받은 코드를 직접 돌리고, 결과를 다시 묻는 반복

제4회

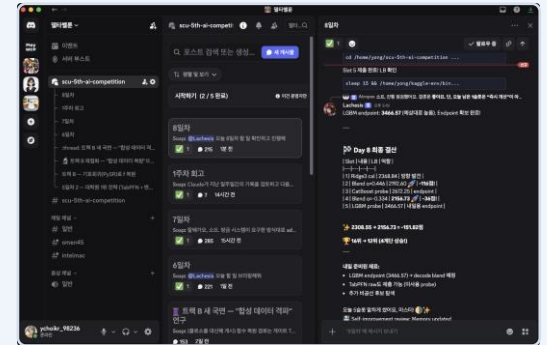
Vibe Coding 검증



'Vibe Coding을 데이터 분석에?' Google Antigravity로 참가

제5회 (이번)

AI 에이전트 팀



AI 에이전트와 인간이 팀을 이뤄 Discord 포럼에서 협업

이번 발표의 초점 — 혼자 참가자가 AI 팀을 운영한 방식

팀 구성 — 모델링보다 판단 구조를 설계했다

Discord 포럼에서 함께 움직인 **Hermes Agent** 팀



라키시스

deepseek-v4-pro

실행·검증

실험 실행 · 제출 · SHA/행수/ID 확인



아트로포스

gpt-5.5

전략·판정

다음 작업 결정 · GO/NO-GO · 결과 해석



클로소

Claude Opus/Sonnet

연구·분석

성능 변화 · 실패 원인 · 대안 탐색




Soap
제안

역할 — 데이터·코드 미열람 · 한 번에 한 에이전트 호출 · 제출 승인 · GO/HOLD/STOP 판단 · 외부 Claude Code: 구성·감사·핵심


세 에이전트를 둔 이유와 비용

핵심 — 비용 절감보다 역할 분리와 작업 편의 · 17일 6.4억 토큰, \$396

토큰 사용량 — 총 6.4억 토큰



API 비용 — 총 \$396



왜 세 에이전트인가

실행·판단·분석의 관심사 분리 · 상호 검증 및 대안 제시

포럼이 공용 작업장

예전엔 한 LLM 답을 다른 LLM에 복사 · 이번엔 모든 결정·근거가 대화로 축적

비용 최적화

라키시스 DeepSeek(토큰 최다·비용 최저) · 클로소 Opus→Sonnet(\$13.5→\$2.9) · Claude Max 플랜 구독 별도

지휘자의 자리 — 어디까지 말고, 어디서 멈췄나

소프의 실제 발화로 본 관여 수준 — 사람이 맡은 일과 맡기지 않은 일

① 방향·전략은 직접



Soap

0.1점 개선이 아니라 획기적인 돌파구를 찾아야 해. 확정 개선보다 probe에 집중하자.

② 외부 지식·판단을 보탬



Soap

합성 데이터를 격파하는 연구라 생각하고 트랙 B를 더 해보자. 0점 낸 학생을 교수님이 1위로 인정했으니, probe 윤리는 문제없어.

③ 세부 수학·구현은 위임



Soap

decode로 누적은 어떤 의미야? 내가 알아듣게 설명해줘. 검증·구현은 너희에게 맡긴다.

④ 막힐 땐 조율역에 자문



Soap

(Claude Code에게) 네가 돌파구를 제안해 줄 수 있나? ... 인가한다, 아트로포스에게 검증받고 진행하자.

사람: 방향·판단·승인 / 에이전트: 데이터·코드·검증

사람의 감은 가설, AI 팀은 검증

소프의 부동산 상식 4가지를 데이터로 검증 — 3개 기각, 1개 수용



Soap

부동산은 단지 브랜드·향·신축 여부·커뮤니티 시설이 집값을 가르잖아. 우리 데이터엔 있어?



클로소

X 3개 기각

확인했어요, 소프. 단지명·향·편의시설은 데이터에 아예 없어요. Distance_to_Subway가 행마다 고유해서 같은 단지끼리 묶는 것도 막혀 있고요.



클로소

✓ 수용

그런데 '신축이냐 구축이냐'(나이)는 달라요 — 모델은 거의 무시하는데(SHAP≈0), 리더보드 잔차엔 나이 구조가 컸어요(decode h=126).



라키시스

그래서 agex지역(신축 프리미엄의 지역차)을 다음 축으로 넣었어요, 마스터.

상식은 가설로만 사용 · 데이터로 확인된 축만 다음 실험

운영 판단 — 로컬 CV를 보되, 공개 LB를 관측 신호로 삼다

로컬 CV만으로 공개 점수를 설명하기 어려운 데이터


cv의 역할 — 제출 전 성능을 가늠하는 로컬 지표. CV 개선 → LB 개선이 전제인데, 이 대회는 그 전제가 약함.

괴리가 커진 배경 세 가지

- 1 **test가 미래 (2026 Q1)** 과거 기반 CV가 미래 test를 대변하지 못함
- 2 **train 시간순 비정렬** 시간 기반 검증이 사실상 무작위 분할로
- 3 **집계 피처의 타깃 결합** 타깃과 강하게 결합될 가능성 → CV 낙관

CV는 보조 지표 · 공개 LB는 이 대회 조건에서 더 직접적인 관측값

로컬 CV와 리더보드 점수의 괴리



기본기는 정공법으로

피쳐 엔지니어링과 앙상블로 예측 재료 확보

피쳐 엔지니어링

- 9피쳐 → 약 120 features (cross-sectional FE)
- fold-safe target encoding — 누수 차단
- 구·동·면적·시점 교차 상호작용
- 거래시점 기반 가격 추세 외삽
- log 변환 + 과소예측(Jensen) 보정

앙상블

Ridge

LGBM

CatBoost

TabPFN

+ 3-way stacking — 서로 다른 학습기로 예측 확장

재료는 충분 · 관건은 near-clone 예측들의 결합 방식

운영 루프 — 방향 설정에서 제출 승인까지

사람: 방향·승인 / 에이전트: 실험·분석·제출

①

피처 엔지니어링

예측 재료 생성

재료

②

앙상블

여러 학습기로 예측 다양화

재료

③

리더보드 디코딩


리더보드 점수로 최적 결합

성적을 만든 결합

핵심 구분

FE·앙상블 = 재료 / 디코딩 = 결합 / 게이트 = 운영 안전장치

작동 사례 1 — 실패한 제출에서 신호를 읽다



나쁜 점수 2368.84 = full-test RMSE 포물선을 읽기 위한 관측점



라키시스

Ridge 앙상블 제출했는데 LB 2368.84, best보다 나빠요. CV는 LB를 예측 못 해요, 마스터.



아트로포스

그 실패도 버릴 게 아니에요, 소프. private LB가 없고 full-test RMSE니 — best와 ridge3 두 점의 점수로 최적 결합 비율을 역산할 수 있어요.



클로소

두 CSV로 산수를 재현했어요, 소프. 한 자리도 안 틀려요 — $\alpha=0.446$, 기대 LB 2192.60.



라키시스

제출 → LB 2192.60! -116점, 디코드 적중이에요. 실패한 점수가 열쇠였어요.

작동 사례 2 — 제출 전 예상과 실제 점수의 일치

endpoint probe로 측정 · 남은 잔차 방향까지 탐색

1

endpoint probe 제출 서로 다른 예측을 끝점으로 — 점수 희생해 포물선 측정

2

달린형 역산 리더보드 RMSE로 최적 α 계산

3

Gram 행렬 확장 축을 늘려 여러 예측을 한꺼번에 결합

4

무작위 직교 잔차 수확 구조축 소진 후 남은 잔차 방향 탐색



아트로포스

소프, ridge3+cat+lgbm 3D decode예요. 어제 endpoint 점수로 최적점을 해석적으로 풀어냈어요.



라키시스


대박이에요 마스터!!! LB 2068.31, 예측 2068.30에서 거의 exact match예요.

제출 전 점수를 계산으로 맞힘

예측 2068.30 → 실측 2068.31 (오차 +0.01) · $\alpha = -0.334$ 에서 2156.73 적중

full-test 점수 구조 기반 정밀 결합

성과 — 운영 루프의 점수 개선



파란 선 = 최고 기록 · 주황 = decode 측정용 probe · 주요 개선 = 관측·검증·승인 루프의 반복 누적

1998.04 최종 RMSE

8위 전체

2위 대학원 그룹

세 번의 도약

- ① 시간+로그편향 보정 3→4일 · -188
- ② decode 발견 7→8일 · -152
- ③ decode 확립 8→9일 · -88

팀 운영은 무엇을 바꿨나

장기전의 효과 — 역할 분리 · 상호 검증 · 장애 복원력

팀 운영이 만든 효과

상호 검증

한 봇의 실수를 다른 봇이 잡음 — 라키시스 오독·scale bug를 아트로포스가, near-clone을 클로소가 적발

관점 다양성

순위를 가른 발상이 서로 다른 모델에서 — decode=아트로포스, 무작위 직교=Claude Code, 게이트=클로소

장애 복원력

필터·크레딧·서버가 막혀도 멈추지 않음 (아래)

대가와 실제 관찰

오버헤드

오케스트레이션 마찰(멘션 규율·verify-on-stop·핸드오프 문서) · 변동비 \$396 · 조율 마찰

실제 데이터

Claude Code의 직접 실행 트랙은 대부분 팀에 추월당함 → Claude Code의 실패는 '직접 실행'이 아니라 '막힌 순간의 방향 제시'(초반 진단·갭 분석·무작위 직교)

장애 복원력 — 단일 장애점 없음

OpenAI 안전 필터 차단
아트로포스 막힘 → 라키시스·클로소로 재배치

OpenRouter 크레딧 소진(402)
라키시스 중단 → 소프 즉시 충전 복구

TabPFN 라이선스 서버 막힘
라키시스 실패 → 소프 라이선스 수락 복구

팀 운영 우위: 장기·대량·다관점 문제 / 단독 실행 우위: 짧은 단발 과제

운영 리스크 — 모델 제공사도 단일 장애점이 될 수 있다

같은 요청도 제공사 정책에 따라 차단 또는 통과



무엇을 하려 했나

아트로포스(gpt-5.5)가 보안 어휘 오탐으로 차단 →
DeepSeek·Anthropic은 동일 작업 수행 가능

무슨 일이 있었나

✗ "This content was flagged for possible cybersecurity risk"

OpenAI 안전 분류기가 공세적 보안 작업으로 보고 응답 거부 (Hermes/게이트웨이 오류 아님)

왜 걸렸나

명세에 "reconstruction attack", "채점기를 정보 누출 채널로", "0 재현" 같은
보안 공격 어휘가 반복 → 분류기가 실질이 아니라 형식 패턴에 반응.

오탐(false positive)인 이유

실제 시스템·개인정보 공격이 아닌 대회 리더보드 상대의 ML 활동(회색지
대·주최가 누수 우승 용인). 같은 작업을 DeepSeek·Anthropic은 수행

오탐을 피하려면

① 프레이밍

"보안 공격" 어휘 대신 "리더보드 최적화" 맥락

② 다중 LLM 폴백

제공사 이원화 — 한 곳 차단 시 다른 모델 수행

③ 범위 명시

대회 규칙·데이터 범위 명시

배운 점 — 다음에는 처음부터 설계

다음 대회에서는 시작 단계부터 적용할 운영 규칙

Hermes 자기개선 — 잘 작동한 것


- ✓ **스킬 자기패치** 실패에서 배운 규칙을 SKILL.md에 되먹임 (ml-competition-workflow 반복 개선)
- ✓ **메모리·프로필 누적** 세션이 바뀌어도 학습 유지
- ✓ **문서화 파이프라인** 전략 메모·핸드오프·리포트·probe 맵 자체 작성 → 재현·협업
- ✓ **게이트·검증 자체 확립** $\cos < 0.9$ 공선성 게이트, 'raw 점수 ≠ h', SHA·행수·ID 재검증
- ✓ **소통 규칙 내재화** 메시지 길이 제한 대응(멘션 맨 뒤) 요령을 스킬로

다음 대회에 보완할 것

- 1 **제출 검증 자동화** 파일·SHA·행수·ID·NaN·스케일 통계 — Day 1 체크리스트로
- 2 **초기 측정기 협력** 1~2일차에 CV/LB 신뢰도·누수·정렬을 함께 확정
- 3 **정기 가정 검증** 3~4·7~8일차 'now 가정이 맞나' 점검 → 오진 6일 단축
- 4 **다중 LLM 풀백** 필터·크레딧 소진 대비 제공사 이원화
- 5 **자율성 경계 정의** '단일 봇 자율' vs '사람 개입 필수' 사전 구분
- 6 **규칙 Day 1 프로토콜화** 멘션·보고·제출 게이트를 사고 후가 아니라 처음부터

Day 1부터 검증 자동화·풀백·정기 점검

인간 감독(Human Oversight) 패턴의 계층 구조



우리 사례에 비춰보기

전략 설계
대회 조건 · 제출 원칙
역할 경계 설정

승인 게이트
GO/HOLD/STOP
제출 전 검증

모니터링
LB 변화 · 오류
필터·크레딧 상태

사후 감사
로그 · SHA · 점수
실패 원인 기록

마무리

사람: 방향·판단·승인 / AI 팀: 탐색·검증·실행

이번 대회에서 한 일

- Hermes Agent 팀이 Discord 포럼에서 진행
- 사람은 데이터·코드 미열람, 지휘·승인만
- CV보다 리더보드를 신호로 사용
- FE·양상블로 재료, 디코딩으로 결합
- 최종 RMSE 1998.04 · 8위 · 그룹 2위

한계

- 새 데이터 일반화를 높인 방법은 아님
- full-test 채점 구조에 특화
- 정답 라벨 신호를 활용(분할 아님)
- row별 복원까지는 안 감
- 531행 복원엔 수백 회 제출 필요 — 예산·기간 한계

사람의 방향·승인과 AI 팀의 탐색·검증·실행을 결합한 사례



감사합니다. · 최용 · SCU_42600055